UNIVERSIDADE FEDERAL DO CEARÁ

PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E DE COMPUTAÇÃO

SEMESTRE 2026.1

COMPARAÇÃO ENTRE OS CLASSIFICADORES K-NN, LDA E QDA

ALUNO: JONAS CARVALHO FORTES

MATRÍCULA: 597158

DISCIPLINA: RECONHECIMENTO DE PADRÕES

PROFESSOR: JARBAS JOACI DE MESQUITA SA JUNIOR

1 OBJETIVOS

Este trabalho tem como objetivo implementar e comparar diferentes métodos de classificação supervisionada no contexto de Reconhecimento de Padrões, analisando seu desempenho na tarefa de classificação de dados biomédicos.

Os seguintes métodos foram avaliados neste relatório:

K-Nearest Neighbors (K-NN), para diferentes valores de k

Linear Discriminant Analysis (LDA)

Quadratic Discriminant Analysis (QDA)

Com isso, busca-se compreender o funcionamento de cada modelo, suas diferenças e os impactos na acurácia e nos erros de classificação.

2 INTRODUÇÃO

Reconhecimento de padrões é uma área do aprendizado de máquina cujo objetivo é atribuir rótulos a amostras com base em suas características. Nesse contexto, cada objeto é representado por um vetor de características em um espaço multidimensional, e a classificação consiste em determinar a qual classe esse vetor pertence.

Os métodos utilizados neste trabalho se dividem em duas categorias principais:

Classificadores não paramétricos: KNN.

Classificadores paramétricos: LDA e QDA.

Os classificadores não paramétricos baseiam-se em uma medida de similaridade entre as amostras e não assumem que os dados tem uma distribuição estatística. Assim, a classificação ocorre por meio de uma distância mínima definida para considerar uma amostra pertencente a uma classe.

Já os classificadores paramétricos assumem que os dados tem uma distribuição estatística, geralmente a distribuição Gaussiana. Assim, a separação entre as classes é feita com base em uma função discriminante calculada através de parâmetros como média e desvio padrão, de modo que é definida fronteiras de decisão entre as classes de dados.

3 IMPLEMENTAÇÃO DOS MÉTODOS

O experimento foi organizado de forma modular, com funções específicas para carregamento do *dataset*, normalização dos dados, execução dos classificadores e avaliação dos resultados.

Inicialmente, o *dataset* ***Vertebral Column 3C*** foi carregada por meio de uma função dedicada, responsável por ler os atributos numéricos e os rótulos textuais das amostras. Assim, cada amostra foi representada por um vetor com seis atributos, enquanto os rótulos originais foram convertidos para representação numérica, adotando-se a codificação: **1 para *normal*, 2 para *disk hernia* e 3 para *spondylolisthesis***.

3.1 Pré-processamento e normalização dos dados

A normalização dos atributos foi feita por meio de padronização z-score. Logo, cada atributo foi ajustado para uma escala com média zero e desvio-padrão unitário, reduzindo os efeitos de diferenças de magnitude entre variáveis. Assim, tratou-se os dados para que atributos com escalas maiores não dominasse indevidamente o calculo de distância nos classificadores não paramétricos.

3.2 Estratégia de validação: Leave-One-Out

Na implementação dos três métodos, para cada índice i, a amostra i foi definida como conjunto de teste, enquanto todas as demais compuseram o conjunto de treinamento. Assim, considerando N amostras, foram realizadas N execuções independentes para cada classificador.

3.3 Implementação do classificador K-NN

O método KNN foi implementado utilizando a **distância Euclidiana**. Em seguida, essas distâncias são ordenadas em ordem crescente, permitindo identificar os k vizinhos mais próximos. Depois, os rótulos dessas k amostras são então selecionados e submetidos a um processo de votação majoritária, no qual a classe mais frequente entre os vizinhos é atribuída como predição final.

Foram feitas execuções para os valores de k de 1 a 5. Assim, para cada valor de k testado, foram armazenadas as predições completas, permitindo o cálculo da acurácia e a construção da matriz de confusão para cada valor de k, possibilitando uma análise do desempenho do

classificador em termos de acertos e erros entre classes e números de k vizinhos.

3.4 Implementação do classificador LDA

Para o método LDA, foram calculadas as médias de cada classe e as probabilidades a priori. Em seguida, foi estimada uma única matriz de covariância global, considerando todas as amostras de treinamento, à qual foi adicionada uma pequena regularização na diagonal para garantir estabilidade numérica durante sua inversão. A classificação de cada amostra de teste foi realizada por meio da avaliação da função discriminante linear. Por fim, a amostra foi atribuída à classe que apresentou o maior valor dessa função discriminante.

3.5 Implementação do classificador QDA

Na implementação do QDA, diferentemente do LDA, assume-se que cada classe possui sua própria matriz de covariância. Assim, para cada classe, foram calculados o vetor de médias, a matriz de covariância da classe e a probabilidade a priori.

A classificação de uma amostra de teste é realizada por meio da avaliação da função discriminante quadrática, que incorpora três componentes principais: o logaritmo do determinante da matriz de covariância, o termo quadrático baseado na distância entre a amostra e a média da classe, e o logaritmo da probabilidade a priori.

3.6 Construção da matriz de confusão

Após a obtenção das predições de cada método, o desempenho foi analisado por meio da matriz de confusão. Essa matriz organiza os resultados de classificação de modo que cada elemento C(i,j) representa a quantidade de amostras cuja classe verdadeira é i e cuja classe predita foi j.

4 RESULTADOS

A avaliação dos modelos foi realizada com base na acurácia e nas matrizes de confusão obtidas. Os resultados são apresentados na Tabela 1:

Tabela 1 – Desempenho dos classificadores K-NN, LDA e QDA

Método	Acurácia
K-NN (k = 1)	0.8065
K-NN (k = 2)	0.7774
K-NN (k = 3)	0.7645
K-NN (k = 4)	0.7484
K-NN (k = 5)	0.7903
LDA	0.8129
QDA	0.8516

Fonte: elaborada pelo autor.

Os resultados apresentados na Tabela 01, mostra diferentes acurácias dos classificadores testados. Assim, observa-se que o método QDA obteve a maior acurácia, indicando maior capacidade inferência devido à consideração de matrizes de covariância distintas para cada classe, o que permite capturar fronteiras de decisão não lineares. Também, o LDA apresentou bom desempenho, sugerindo que uma separação linear entre as classes é suficiente para um bom índice de acertos. No caso do K-NN, verifica-se sensibilidade ao parâmetro k, com melhor desempenho para k=1, seguido de uma queda gradual na acurácia para valores intermediários e uma leve recuperação em k=5. Esse comportamento indica um possível equilíbrio entre *overfitting* com k pequeno e relaxamento de distância com k maior. De modo geral, os resultados sugerem que abordagens paramétricas mais flexíveis, como o QDA, são mais adequadas para o conjunto de dados em questão, o que indica que há distribuições distintas entre as classes.

Figura 01 – Matriz confusão 1-NN

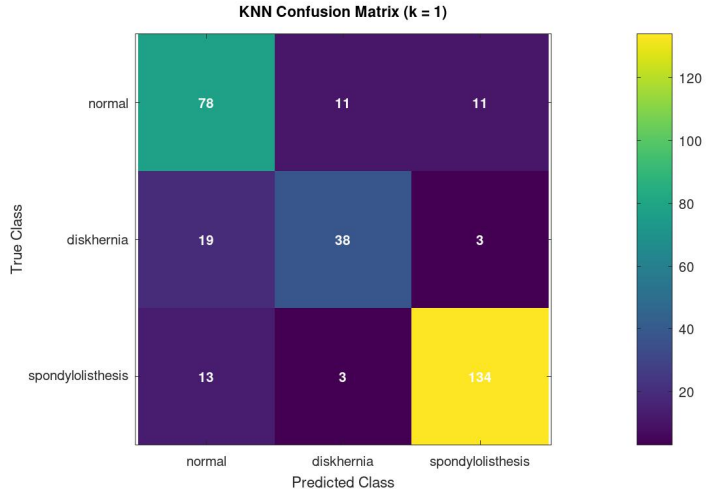

Figura 02 – Matriz confusão 2-NN

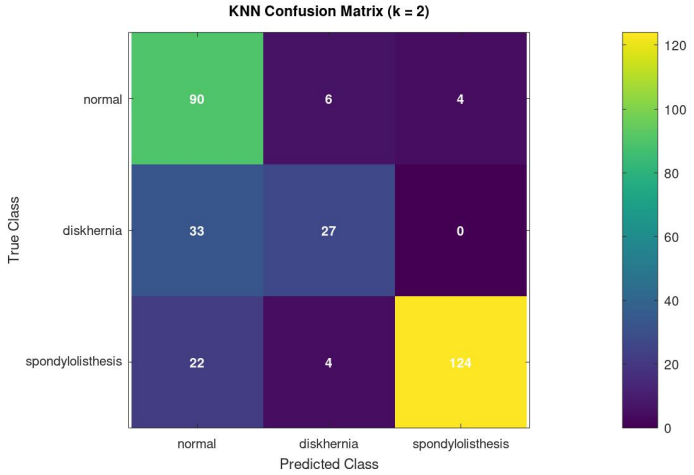

Figura 03 – Matriz confusão 3-NN

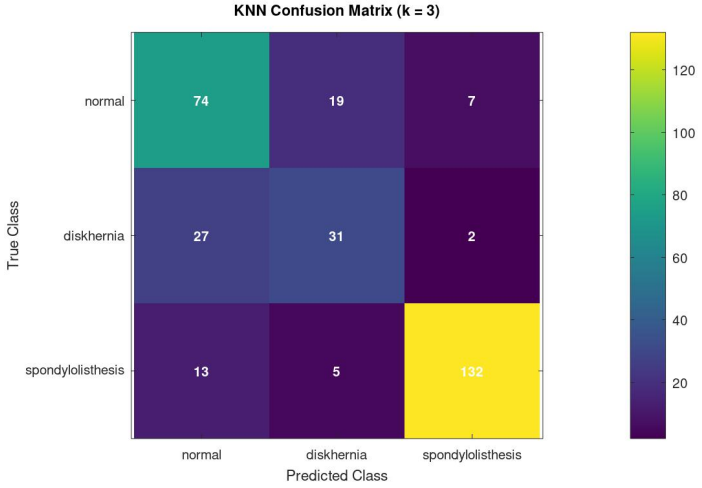

Figura 04 – Matriz confusão 4-NN

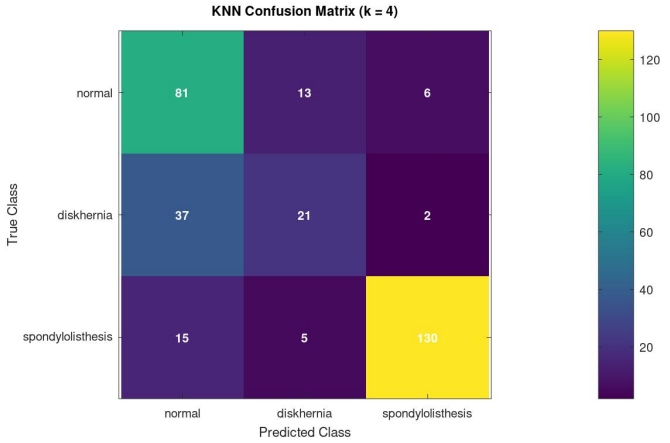

Figura 05 – Matriz confusão 5-NN

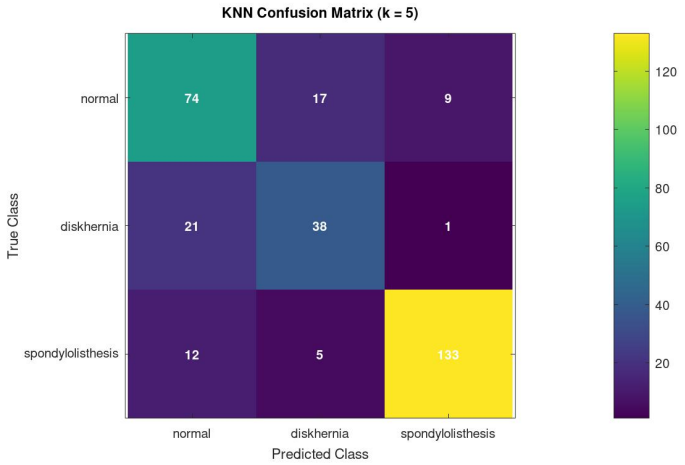

Nas Figuras de 1 a 5, são apresentadas as matrizes de confusão do modelo K-NN para os parâmetros de K definidos.

Ao analisar as matrizes de confusão do classificador K-NN para diferentes valores de k fica evidente o impacto desse parâmetro na distribuição dos erros entre as classes. De forma geral, observa-se que a classe *spondylolisthesis* apresenta alta taxa de acerto e boa separabilidade em relação às demais classes. Por outro lado, a classe *disk hernia* é a mais problemática, apresentando elevada confusão com a classe *normal*, o que sugere sobreposição entre essas classes no espaço de características. Para k=1, o modelo apresenta maior sensibilidade às amostras individuais, resultando em bons acertos, mas ainda com erros relevantes entre *normal* e *disk hernia*. À medida que k aumenta (especialmente em k=3 e k=4), nota-se uma maior suavização da decisão, porém com aumento da confusão entre essas duas classes, indicando possível perda de detalhes locais importantes. Em k=5, observa-se um leve equilíbrio, com redução de alguns erros extremos, mas ainda mantendo a tendência de confusão entre *normal* e *disk hernia*. Esses resultados reforçam que valores baixos de k capturam melhor estruturas locais, enquanto valores maiores tendem a generalizar mais, porém com perda de precisão em regiões de sobreposição entre classes.

Figura 06 – Matriz confusão LDA

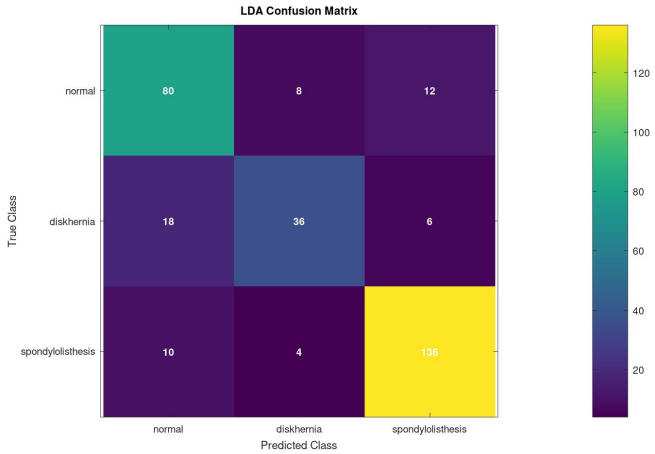

Figura 07 – Matriz confusão QDA

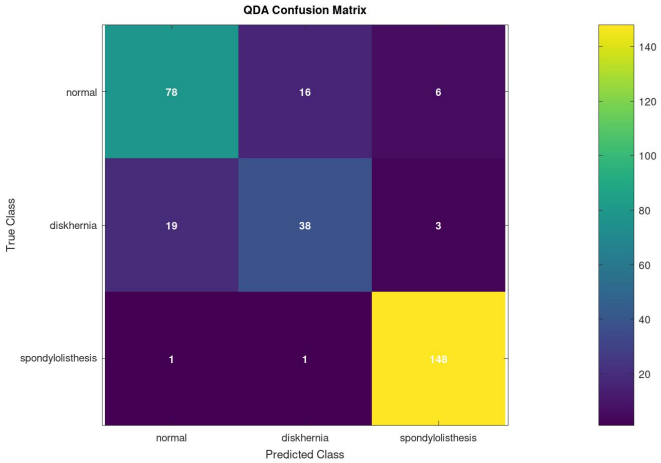

Nas Figuras de 6 a 7, são apresentadas as matrizes de confusão do modelo LDA e QDA.

No caso do LDA, observa-se um bom desempenho geral, com altos valores na diagonal principal, especialmente para a classe *spondylolisthesis*, que apresenta elevada taxa de acerto. No entanto, ainda há confusão significativa entre as classes *normal* e *disk hernia*. Esse comportamento é consistente com a hipótese de que a covariância compartilhada limita sua capacidade de modelar diferenças estruturais mais complexas entre as classes. Já o QDA apresenta desempenho superior, com uma matriz de confusão mais concentrada na diagonal principal, destacando-se pela quase perfeita classificação da classe *spondylolisthesis* e pela redução dos erros entre as demais classes. A diminuição das confusões, especialmente entre *normal* e *disk hernia*, indica que o QDA consegue capturar melhor as diferenças de dispersão entre as classes, graças ao uso de matrizes de covariância específicas. Dessa forma, os resultados sugerem que o QDA é mais adequado para o conjunto de dados analisado, pois modela de maneira mais eficiente as fronteiras de decisão não lineares presentes no problema.

5 CONCLUSÃO

De forma geral, os resultados obtidos demonstram que a escolha do classificador está diretamente relacionada às características do conjunto de dados. O método QDA apresentou o melhor desempenho, evidenciando sua capacidade de modelar distribuições com diferentes padrões de dispersão e capturar fronteiras de decisão não lineares. O LDA também apresentou resultados satisfatórios, indicando que uma separação linear é parcialmente adequada, embora limitada pela suposição de covariância compartilhada entre as classes. Já o K-NN mostrou-se sensível ao parâmetro k, evidenciando a capacidade de equilíbrio entre sobreajuste e generalização. A análise das matrizes de confusão reforçou que a principal dificuldade do problema está na distinção entre as classes *normal* e *disk hernia*, enquanto a classe *spondylolisthesis* apresenta boa separabilidade. Assim, conclui-se que abordagens paramétricas mais flexíveis, como o QDA, são mais adequadas para o conjunto de dados analisado.